

소규모 오프라인 매장(정육점)

고객 이탈 예측 모델 개발

— 개인별 방문 패턴 기반 이탈 기준 도출 및 Random Forest 초기 분석 —

분석 대상	파일럿 정육점 1 개
데이터 기간	2024 년 4 월 ~ 2026 년 3 월 (약 2 년)
분석 고객 수	1,258 명 (5 회 이상 + 3 등분 가능 고객)
핵심 방법론	개인별 3 등분 방문 패턴 변화율 분석 + Random Forest
작성일	2026 년 4 월

목차

- 1 장. 연구 배경 및 목적
- 2 장. 데이터 현황
- 3 장. 분석 대상 고객 선정 — 왜 5 회 이상인가
- 4 장. 이탈(Churn)을 어떻게 정의할 것인가
- 5 장. 개인별 3 등분 방법론 — 설계 근거
- 6 장. 이탈 기준: 변화율 1.5 — 왜 이 숫자인가
- 7 장. Random Forest 모델 — 처음부터 이해하기
- 8 장. 모델 성능 평가 지표 해설
- 9 장. 분석 결과
- 10 장. 종합 해석 및 한계점

1 장. 연구 배경 및 목적

1.1 문제 인식

50~60 대 소규모 오프라인 매장 사장님들은 디지털 취약계층으로, 단골 고객이 언제부터 안 오기 시작했는지를 파악하기가 매우 어렵다. 대형 마트나 이커머스 플랫폼은 이미 AI 기반 고객 이탈 예측 시스템을 운영하고 있지만, 동네 정육점 같은 소규모 오프라인 매장에는 이런 도구가 전혀 없는 상황이다.

핵심 문제: 단골 고객이 점점 뜸하게 오기 시작해도, 사장님은 수개월이 지나서야 인지한다. 이 시점에는 이미 고객이 다른 가게로 완전히 넘어간 상태일 가능성이 높다. 이 연구는 "누가 이탈할 것 같은가"를 미리 감지하는 AI 모델을 개발하는 것을 목표로 한다.

- 기존 이탈 예측 연구는 전부 이커머스·구독 서비스 기반 → 오프라인 소규모 매장 특화 연구 전무
- 단순히 "왔다/안왔다"가 아니라, 방문 빈도가 줄어드는 추세 자체를 이탈 신호로 포착
- 국가전략기술 AI 분야 디딤돌 R&D 과제 1 단계 연구

1.2 이 보고서가 답하는 것

연구 질문	이 보고서의 답
이탈을 어떻게 정의할 것인가?	개인별 방문 간격의 변화율로 정의(단순 미방문이 아닌 "점점 느려지는 추세")
분석 대상을 왜 5 회 이상으로 잡았는가?	5 회 미만은 패턴이라 부를 수 없음데이터 기반 근거 제시
왜 3 등분인가?	개인 전체 기간을 3 구간으로 나눠초반→중반→후반 변화를 추적
이탈 기준을 왜 변화율 1.5 로 잡았는가?	전체 고객 중앙값이 1.33→ 정상 범위를 벗어난 1.5 를 기준으로 설정
Random Forest 모델은 얼마나 정확한가?	AUC 0.773 달성피처 중요도 분석 결과 포함

2 장. 데이터 현황

항목	내용
매장	파일럿 정육점 1 개
데이터 기간	2024 년 4 월 9 일 ~ 2026 년 3 월 10 일 (약 2 년)
총 거래 건수	51,068 건
전체 고유 회원 수	3,589 명
데이터 내용	영업일자, 회원명, 상품정보, 구매금액
고객 식별 방법	회원명 기반 (전화번호 해시 매칭 추후 적용 예정)
전체 평균 방문 횟수	14.2 회 / 중앙값 6 회 (2 년 합산)
5 회 이상 고객 평균	23 회 / 중앙값 15 회

중앙값 해석: 5 회 이상 고객의 중앙값이 15 회 / 24 개월 = 약 한 달 반(47 일)에 한 번 방문.
즉 이 매장의 전형적인 단골 고객은 한 달 반에 한 번 오는 고객이다.

3 장. 분석 대상 고객 선정 — 왜 5 회 이상인가

3.1 5 회 미만을 제외하는 이유

이탈 예측 모델은 "방문 패턴"을 학습한다. 패턴이 존재하려면 최소한의 방문 기록이 필요하다. 방문이 1~4 번밖에 없는 고객은 아래 두 가지를 구분할 수 없다.

상황	방문 횟수	실제 의미	이탈인가?
3 회 방문 후 6 개월 미방문	3 회	이탈했을 가능성 높음	이탈일 수도
원래 1 년에 3 번만 오는 고객	3 회	정상 패턴	이탈 아님
최근 가입한 신규 고객	3 회	아직 패턴 형성 중	판단 불가

방문 횟수가 적으면 위 세 상황을 구분할 방법이 없다. 따라서 패턴 분석이 의미있으려면 최소 5 회 이상의 방문 기록이 필요하다.

3.2 분석 대상 선정 결과




그림 1. 분석 대상 고객 선정 과정

단계	고객 수	제외/선정 이유
전체 고객	3,589 명	2024 년 4 월 ~ 2026 년 3 월 전체

단계	고객 수	제외/선정 이유
5 회 미만 제외	-1,501 명	패턴 없음. 신규 고객 또는 저빈도 방문자
5 회 이상 (분석 대상)	2,088 명	방문 패턴 분석 가능한 단골 고객
3 등분 가능	1,278 명	개인 기간을 3 구간으로 나눌 수 있는 고객
최종 모델 학습 대상	1,258 명	결측값 제거 후

4 장. 이탈(Churn)을 어떻게 정의할 것인가

4.1 기존 방식의 문제: "왔다/안왔다"

이탈을 정의하는 가장 단순한 방법은 "특정 기간에 방문했는가/안했는가"다. 예를 들어 "2024 년에 왔다가 2025 년에 안 오면 이탈"처럼. 그러나 이 방식에는 치명적인 문제가 있다.

고객	실제 상황	기존 방식 판단	문제점
김씨	2024 년 매주 오다가 12 월부터 뚝 끊김	정상(2025 년에 한 번 왔으니까)	이미 이탈 신호가 있었는데 놓침
박씨	원래 분기에 한 번 오는 고객 2025 년에 한 번도 안 옴	이탈	단순히 그 분기가 바뀐 시기였을 수도
이씨	2024 년에 잘 오다가 2025 년엔 간격이 2 배 늘어남	정상(왔으니까)	방문 빈도 감소 신호를 완전히 무시

4.2 새로운 정의: 이탈은 사건이 아니라 과정이다

핵심 아이디어: "안 왔다"가 이탈이 아니라, "점점 덜 오고 있다"가 이탈의 신호다.
방문이 완전히 끊기기 전에, 방문 간격이 서서히 늘어나는 추세를 포착하는 것이 목표다.

이를 위해 각 고객의 방문 기록을 시간 순서대로 나열하고, 전반부와 후반부의 방문 간격을 비교한다. 간격이 늘어날수록 이탈 위험이 높아진다고 판단한다.

5 장. 개인별 3 등분 방법론 — 설계 근거

5.1 왜 "개인별" 기간인가

"3 등분"을 2024 년 1 월~4 월, 2024 년 5 월~8 월처럼 달력 기준으로 나누면 안 된다. 고객마다 처음 방문한 날짜가 다르기 때문이다. 2024 년 10 월에 처음 온 고객에게 2024 년 1~4 월 기간을 적용하면 데이터가 없다.

원칙: 각 고객의 "첫 방문일 ~ 마지막 방문일"을 그 고객의 전체 기간으로 정의한다.
이 기간을 3 등분하여 1 구간(초반) / 2 구간(중반) / 3 구간(후반)으로 나눈다.
비교 기준이 고객마다 달라지기 때문에 개인화된 이탈 판단이 가능하다.

5.2 3 등분 개념 예시




그림 2. 개인별 3 등분 방식 예시 (이씨=충성도 증가, 김씨=안정, 박씨=이탈 위험)

위 그림에서 박씨의 경우 1 구간과 2 구간에서는 방문 간격이 비슷하지만, 3 구간에서 급격히 늘어나는 것을 확인할 수 있다. 이것이 이탈 위험 신호다.

5.3 왜 3 등분인가 (2 등분이 아닌 이유)

- 2 등분: 전반부 vs 후반부만 비교 → "이미 느려진 것"만 감지, 중간 추세 변화를 놓침
- 3 등분: 1→2 구간 변화(초반 추세) + 2→3 구간 변화(후반 추세)를 모두 포착 가능
- 특히 1→2 구간 변화율이 피처로 활용되어 "초반부터 느려지기 시작한 고객"을 조기에 감지

5.4 왜 5 회 이상인데 일부는 3 등분이 불가한가

3 등분이 되려면 각 구간에 방문이 최소 2 번 이상 있어야 간격을 계산할 수 있다. 그런데 방문이 특정 시기에 몰려있으면 한 구간에 방문이 1 번밖에 없을 수 있다.

예시: 8 번 방문한 고객이 모두 2024 년 4~6 월에만 집중 방문하고 이후 뜸해진 경우
→ 전체 기간(2024.4 ~ 2026.3)을 3 등분하면 1 구간에 8 번, 2 구간과 3 구간에 0 번
→ 2 구간과 3 구간은 간격 계산 불가 → 3 등분 불가 처리

방문 횟수 기준	전체 고객	3 등분 가능	가능 비율
5 회 이상	2,088 명	1,278 명	61.2%
6 회 이상	1,911 명	1,278 명	66.9%
7 회 이상	1,784 명	1,268 명	71.1%
8 회 이상	1,652 명	1,246 명	75.4%
9 회 이상	1,522 명	1,211 명	79.6%
10 회 이상	1,420 명	1,174 명	82.7%

방문 횟수가 많을수록 3 등분 가능 비율이 높아진다. 8 회 이상이면 75.4%가 3 등분 가능하다. 5 회 이상 기준을 유지하되, 3 등분이 불가한 고객(810 명)은 이번 모델에서 제외하고 추후 별도 처리 방안 검토.

6 장. 이탈 기준: 변화율 1.5 — 왜 이 숫자인가

6.1 변화율이란

변화율 = 2→3 구간 평균 방문 간격 ÷ 1→2 구간 평균 방문 간격

변화율	의미	예시
0.8 미만	간격이 짧아짐 (방문 빈도 증가)	중반에 30 일이었는데 후반에 24 일
0.8 ~ 1.2	거의 변화 없음 (안정적 단골)	중반 30 일 → 후반 30 일
1.2 ~ 1.5	간격이 약간 늘어남 (주의)	중반 30 일 → 후반 40 일
1.5 이상	간격이 50% 이상 늘어남 (이탈 위험)	중반 30 일 → 후반 45 일 이상
2.0 이상	간격이 2 배 이상 늘어남 (이탈 임박)	중반 30 일 → 후반 60 일 이상

6.2 왜 1.5 를 기준으로 잡았는가




그림 3. 방문 간격 변화율 분포 (왼쪽: 1→2 구간, 오른쪽: 2→3 구간)

위 그래프에서 오른쪽(2→3 구간 변화율 분포)을 보면, 전체 고객의 중앙값이 1.33 이다. 즉 아무 문제 없는 일반 고객도 후반부로 갈수록 방문 간격이 33% 정도 늘어나는 것이 자연스러운 현상이다.

근거: 전체 고객 중앙값 = 1.33 (정상 고객도 후반부에 33% 느려짐)

→ 1.33 은 정상 범위 내

→ 1.5 이상이면 정상 범위를 벗어난 것으로 판단

→ 1.5 를 이탈 위험 기준으로 설정

이 기준은 임의로 정한 것이 아니라 실제 데이터의 분포에서 도출한 값이다.

기준 적용 결과	수치
분석 대상 (3 등분 가능)	1,278 명
이탈 위험 (변화율 ≥ 1.5)	554 명 (44.0%)
정상 (변화율 < 1.5)	704 명 (56.0%)

7 장. Random Forest 모델 — 처음부터 이해하기

7.1 왜 Random Forest 를 쓰는가

"변화율 1.5 이상이면 이탈"이라고 이미 기준을 정했는데, 왜 또 Random Forest 가 필요한가? 이 질문이 당연하다. 두 가지 이유가 있다.

- **이유 1 — 미래 예측:** 변화율은 과거 데이터로 계산된다. 하지만 우리가 원하는 건 "지금 이 고객이 앞으로 이탈할 것인가"다. Random Forest 는 현재 상태(방문 횟수, 간격, 변화 추세 등)를 보고 이탈 확률을 예측한다.
- **이유 2 — 복합 패턴 학습:** 이탈 위험은 변화율 하나만으로 결정되지 않는다. 방문 횟수, 마지막 방문 후 경과일, 구매 금액 변화 등 여러 요소가 복합적으로 작용한다. Random Forest 는 이 복잡한 패턴을 자동으로 학습한다.

7.2 결정 트리(Decision Tree)부터 이해하기

Random Forest 를 이해하려면 먼저 결정 트리를 알아야 한다. 결정 트리는 "스무고개"와 같다.

결정 트리 예시 (정육점 이탈 예측 스무고개):

Q1. 마지막 방문 후 60 일이 넘었나?

→ YES: Q2 로 이동

→ NO: 정상 (이탈 확률 낮음)

Q2. 2→3 구간 변화율이 2.0 이상인가?

→ YES: 이탈 임박 (확률 89%)

→ NO: Q3 으로 이동

Q3. 평균 방문 간격이 45 일 이상인가?

→ YES: 이탈 위험 (확률 67%)

→ NO: 주의 (확률 43%)

이런 질문 순서와 기준값을 데이터에서 자동으로 찾아내는 것이 "학습"이다.

7.3 결정 트리 하나의 문제점

결정 트리를 하나만 쓰면 두 가지 문제가 생긴다.

- 과적합(Overfitting): 학습 데이터에 너무 딱 맞게 만들어져서 새로운 고객 데이터에는 잘 안 맞음. 마치 작년 시험 문제만 외워서 새 시험에 못 하는 것과 같다.
- 불안정성: 데이터에서 고객 한 명만 바뀌어도 트리 구조가 크게 달라짐. 믿을 수가 없다.

7.4 Random Forest = 결정 트리 500 개의 다수결

비유: 의사 한 명한테만 진단받는 것(결정 트리 1 개) vs

의사 500 명이 각자 독립적으로 진단하고 다수결로 최종 결정하는 것(Random Forest)
한 명이 틀려도 나머지 499 명이 바로잡는다.

단계	무슨 일이 일어나는가
1 단계 Bagging(데이터 샘플링)	1,258 명 전체 데이터에서 무작위로 약 1,000 명을 뽑아 트리 1 학습또 다른 1,000 명을 뽑아 트리 2 학습이걸 500 번 반복 (중복 허용)→ 트리마다 보는 데이터가 조금씩 다름
2 단계 Feature Randomness(변수 무작위 선택)	각 질문(분기)에서 8 개 변수 중 2~3 개만 무작위로 선택→ 트리마다 보는 변수도 다름→ 500 개 트리가 서로 다른 관점에서 판단
3 단계다수결 최종 예측	트리 500 개가 각자 "이탈 위험/정상" 예측→ 이탈 위험이라고 한 비율 = 이탈 확률예: 500 개 중 420 개가 이탈 위험 → 이탈 확률 84%

7.5 모델 입력 변수 (피쳐)

모델은 각 고객의 아래 8 가지 정보를 입력받아 이탈 확률을 출력한다.

변수명	의미	계산 방법
방문 횟수	전체 기간 동안 총 방문 횟수	단순 카운트
마지막 방문 경과일	마지막 방문 후 지금까지 며칠이 지났는가	기준일(2026.3.10) - 마지막 방문일
전체 평균 방문 간격	방문과 방문 사이 평균 일수	전체 방문 간격의 평균

변수명	의미	계산 방법
방문 간격 표준편차	방문이 얼마나 불규칙한가(작을수록 규칙적, 클수록 불규칙)	전체 방문 간격의 표준편차
평균 구매 금액	방문당 평균 구매 금액	총 구매금액 ÷ 방문 횟수
1 구간 평균 간격 ★	초반부 방문 간격 평균(개인 전체 기간 1/3 구간)	3 등분 설계에서 신규 추가
2 구간 평균 간격 ★	중반부 방문 간격 평균(개인 전체 기간 2/3 구간)	3 등분 설계에서 신규 추가
1→2 구간 변화율 ★	초반→중반 방문 간격 변화(1 보다 크면 느려지는 중)	2 구간 평균 ÷ 1 구간 평균

★ 표시된 3 개 변수는 개인별 3 등분 설계에서 새로 추가된 변수다. 기존 분석에서는 없었던 변수로, 이번 설계의 핵심이다.

7.6 이탈 라벨 (정답 데이터)

Random Forest 는 지도 학습(Supervised Learning) 방법이다. 즉 "정답"이 있어야 학습할 수 있다. 이 연구에서 정답은 다음과 같이 정의한다.

이탈 라벨 정의:

각 고객의 2→3 구간 변화율(후반부 방문 간격 / 중반부 방문 간격)이 1.5 이상이면 → 이탈 위험 (라벨 = 1)

1.5 미만이면 → 정상 (라벨 = 0)

이 라벨을 정답으로 사용하여 모델을 학습시킨다.

모델은 1~2 구간의 정보(피쳐)만 보고 3 구간 변화를 예측하도록 학습된다.

8 장. 모델 성능 평가 지표 해설

이 장에서는 모델이 얼마나 잘 작동하는지 판단하는 지표들을 설명한다. 각 지표의 개념, 해석 기준, 우리 모델의 수치를 함께 제시한다.

8.1 혼동 행렬 (Confusion Matrix) — 모든 지표의 기초

모델의 예측 결과를 2×2 표로 정리한 것이다. 이 표에서 모든 성능 지표가 계산된다.




그림 4. 혼동 행렬 (임계값 50% 기준)

용어	의미	비유
TP (진짜 양성)	실제 이탈 → 이탈로 올바르게 예측	아픈 사람을 아프다고 진단 ✓
FP (거짓 양성, 오탐)	실제 정상 → 이탈로 잘못 예측	건강한 사람을 아프다고 진단 ✗
FN (거짓 음성, 미탐)	실제 이탈 → 정상으로 잘못 예측	아픈 사람을 건강하다고 진단 ✗
TN (진짜 음성)	실제 정상 → 정상으로 올바르게 예측	건강한 사람을 건강하다고 진단 ✓

8.2 AUC (Area Under the ROC Curve)

모델이 이탈 고객과 정상 고객을 얼마나 잘 구분하는가를 나타내는 지표다. 0.5~1.0 사이의 값을 가진다.




그림 5. ROC 곡선 (AUC = 0.773)

AUC 값	해석	우리 모델
0.5	무작위 예측과 동일. 전혀 의미 없음	
0.6 ~ 0.7	약한 예측력. 개선 필요	
0.7 ~ 0.8	적정 수준. 실용적으로 사용 가능	← 우리 모델 (0.773)
0.8 ~ 0.9	좋은 예측력	
0.9 이상	매우 좋은 예측력	

AUC 0.773의 의미: 무작위로 이탈 고객 1명과 정상 고객 1명을 뽑았을 때, 모델이 이탈 고객에게 더 높은 이탈 확률을 줄 확률이 77.3%다. 초기 분석(피처 8개, 매장 1개)으로는 양호한 수준이다.

8.3 F1 점수

이탈 고객(44%)과 정상 고객(56%)이 불균형한 상황에서 적합한 지표다. 정밀도와 재현율의 균형을 측정한다.

지표	의미	공식
정밀도 (Precision)	이탈로 예측한 것 중 진짜 이탈 비율(모델이 이탈이라고 판단한 고객 중 실제로 이탈 위험인 고객의 비율)	$TP \div (TP + FP)$
재현율 (Recall)	실제 이탈 중 모델이 잡아낸 비율"이탈 고객을 얼마나 놓치지 않았는가"	$TP \div (TP + FN)$
F1 점수	정밀도와 재현율의 균형 지표 0 에 가까울수록 나쁨, 1 에 가까울수록 좋음	$2 \times (\text{정밀도} \times \text{재현율}) \div (\text{정밀도} + \text{재현율})$

8.4 OOB Score (Out-Of-Bag Score)

Random Forest 에서만 사용 가능한 특수한 자체 검증 방법이다. Bagging 과정에서 각 트리가 학습에 사용하지 않은 데이터(OOB 데이터)로 성능을 평가한다. 별도의 검증 데이터 없이도 과적합 여부를 확인할 수 있다.

9 장. 분석 결과

9.1 모델 성능 요약

성능 지표	값	해석	목표치
AUC	0.773	이탈/정상 구분 능력 적정 수준	0.75 이상 ✓ 달성
OOB Score	0.715	학습 데이터 내 자체 검증 정확도	-
F1 점수 (임계값 50%)	0.639	이탈 예측 균형 지표	개선 목표
정확도 (임계값 50%)	0.687	전체 예측 정확도	-

AUC 0.773 으로 목표치(0.75) 초과 달성. 피쳐 8 개, 매장 1 개 데이터만으로 실용적 수준 확인.

9.2 피쳐 중요도 — 무엇이 이탈을 결정하는가




그림 6. Random Forest 피쳐 중요도 (빨간색 = 3 등분 신규 추가 변수)

순위	변수	중요도	해석
1 위	2 구간 평균 간격 ★	22.4%	중반부 방문 패턴이 이탈 예측에 가장 중요→ 중반부부터 느려지기 시작하면 위험 신호

순위	변수	중요도	해석
2 위	1→2 구간 변화율 ★	13.7%	초반→중반 변화 추세 자체가 중요→ 조기 감지 가능성 확인
3 위	표준편차	12.5%	방문 불규칙성이 이탈과 연관→ 불규칙해질수록 이탈 위험 상승
4 위	전체 평균 방문 간격	12.1%	기본 방문 주기 자체가 중요
5 위	마지막 방문 경과일	11.7%	오래 안 올수록 이탈 위험
6 위	1 구간 평균 간격 ★	11.5%	초반부 패턴이 기준점 역할
7 위	평균 구매 금액	8.4%	구매 금액도 이탈과 관련
8 위	방문 횟수	7.7%	총 방문 이력

핵심 발견: 3 등분 설계에서 새로 추가한 3 개 변수(2 구간 평균 간격, 1→2 구간 변화율, 1 구간 평균 간격)가 전체 중요도의 47.6%를 차지한다. 3 등분 설계의 타당성이 데이터로 확인됐다.

9.3 이탈 확률 분포




그림 7. 전체 고객 이탈 확률 분포

구간	고객 수	비율	활용 방안
이탈 임박 (70% 이상)	354 명	28.1%	2 단계 실험 대상: LLM vs 규칙 vs 미발송
이탈 위험 (50~70%)	200 명	15.9%	3 단계 실험 대상: LLM 개인화 depth 비교
주의 (30~50%)	178 명	14.1%	3 단계 실험 대상
정상 (30% 미만)	526 명	41.8%	별도 액션 불필요

10 장. 종합 해석 및 한계점

10.1 핵심 발견 요약

번호	발견	의미
1	AUC 0.773 달성 (목표 0.75 초과)	초기 모델로 실용적 수준 확인
2	3 등분 신규 변수 3 개가 중요도 상위 47.6% 차지	개인별 3 등분 설계의 타당성 데이터로 검증
3	2 구간 평균 간격이 1 위 (22.4%)	중반부 패턴이 이탈 예측에 가장 중요
4	전체 고객 2→3 구간 변화율 중앙값 = 1.33	정상 고객도 후반부에 33% 느려지는 것이 자연스러움→ 1.5 를 이탈 기준으로 설정한 근거
5	이탈 임박(70%+) 354 명 감지	2 단계 LLM 실험 대상 확보

10.2 현재 분석의 한계점

한계점	내용	해결 방안
단일 매장 데이터	파일럿 1 개 매장만 사용결과를 일반화하기 어려움	3 개 매장 통합 분석으로 확장
회원명 기반 매칭	동명이인 문제 발생 가능	전화번호 SHA-256 해시 매칭 적용
3 등분 불가 810 명 제외	전체 5 회 이상 고객의 38.8%가 분석에서 빠짐	2 등분 또는 다른 방식으로 별도 처리 검토
계절성 미처리	명절/계절 효과가 패턴에 노이즈 가능성	명절 전후 2 주 제외 + 계절 변수 추가
이탈 기준 1.5 미검증	3 개 매장 통합 분석 후 재검증 필요	다매장 데이터로 최적 기준값 재산출

10.3 다음 단계

단계	내용	시기
단기	3 개 매장 통합 분석전화번호 해시 매칭 적용계절성 처리 적용	2026 년 하반기
중기	이탈 기준(1.5) 재검증 3 등분 불가 고객 처리 방안 개발임계값 최적화	2026 년 말
장기	2 단계 실험 (LLM vs 규칙 vs 미발송)3 단계 실험 (LLM 개인화 depth)AUC 0.80 이상 달성 목표	2027 년

— 보고서 끝 —

다음 단계: 2 단계 실험 설계 (LLM vs 규칙 vs 미발송)