

AI 기반 고객관리 자동화 시스템

연구개발 방법론

— 팀원 공유용 상세 방법론 문서 —

연구 기간	2026년 7월 ~ 2027년 12월 (1년 6개월)
연구 단계	3단계 (이탈 예측 모델 → LLM 효과 실험 → 개인화 depth 실험)
파일럿 매장	정육점 1개 (초기) → 최대 5개 확장
작성일	2026년 4월 16일 2시

목차

- 1장. 연구 배경 및 전체 구조
- 2장. 연구 대상 및 데이터
- 3장. (1단계) 방문주기 예측 모델 및 이탈 기준 도출
- 4장. (2단계) LLM vs 규칙 기반 문자 효과 실험
- 5장. (3단계) LLM 개인화 depth 실험
- 6장. 실험 운영 시스템
- 7장. 성과 목표 및 기대 효과
- 부록. 미발송 그룹(C그룹) 포함 여부 검토

1장. 연구 배경 및 전체 구조

1.1 연구의 필요성

50~60대 소규모 오프라인 매장 사장님들은 디지털 취약계층으로, 단골 고객이 언제부터 안 오기 시작했는지 파악하기 어렵다. 기존 CRM 솔루션은 이커머스·대기업 중심으로 설계되어 있어 소규모 오프라인 매장에는 적합하지 않다.

기존 CRM과의 핵심 차별점:

기존 CRM: 사람이 이탈 기준을 정하고, 동일한 템플릿 문자를 발송

본 연구: AI가 개인별 방문 패턴에서 이탈 기준을 자동 도출하고, 고객마다 완전히 다른 개인화 문자를 생성·발송

→ 사장님은 버튼 하나만 누르면 된다

1.2 연구 3단계 구조

단계	연구 내용	핵심 질문	기간
1단계방문주기 예측 모델	개인별 방문 패턴 변화율 분석Random Forest 이탈 예측 모델 개발	정육점 고객의 이탈을 어떻게 정의하고 예측할 것인가?	2026년 7월(모델 완성)
2단계LLM 효과 실험	이탈 위험 고객 대상LLM 개인화 문자 vs 규칙 기반 문자효과 비교	LLM 개인화 문자가 규칙 기반 문자(템플릿) 보다 재방문을 더 유도하는가?	2026년 7~11월(5개 월)
3단계Depth 실험	전체 고객 대상LLM 개인화 깊이(depth) 3단계효과 비교	개인화가 깊을수록 재방문 빈도가증가하는가?	2026년 7~11월(2단 계와 동시)

주목: 2단계와 3단계는 동시에 진행된다.

2단계 대상(이탈 확률 50% 이상)과 3단계 대상(이탈 확률 50% 미만)이 겹치지 않아 동시 실험이 가능하다.

계절 효과도 동일하게 통제된다.

2장. 연구 대상 및 데이터

2.1 파일럿 매장 구성

구분	내용
초기 파일럿	정육점 1개 (1단계 모델 개발 및 초기 실험)
확장 파일럿	최대 5개 매장으로 확장 (모델 고도화)
신규 매장 적용	5개 매장 통합 모델을 6번째 이후 신규 매장에 적용

2.2 보유 데이터 현황 (1개 매장 기준)

항목	현황
데이터 기간	2024년 4월 ~ 2026년 3월 (약 2년)
총 거래 건수	51,068건
전체 고유 회원 수	3,589명
분석 대상 (5회 이상)	2,088명
모델 학습 대상 (3등분 가능)	1,258명
전체 평균 방문 횟수	14.2회 / 중앙값 6회
5회 이상 고객 평균	23회 / 중앙값 15회 (약 한 달 반에 1회)

2.3 실험 시작 시 데이터 재처리

실험 시작일(2026년 7월 1일)에 다음 절차로 데이터를 재처리한다.

- 2024년 4월 ~ 2026년 6월 전체 데이터로 모델 재학습
- 최근 6개월 이상 미방문 고객(2026년 1월 이전 마지막 방문) → 이미 이탈 확정으로 판단하여 실험 대상에서 제외
- 나머지 활성 고객 기준으로 이탈 확률 재산출
- 직전 3개월(2026년 4~6월) 방문 간격을 실험 전 기준으로 설정

이유: 2024년부터의 자료로 세운 기준치에는 이미 이탈한 고객이 포함되어 있을 수 있다. 실험 시작 시점에 재처리하여 실제 활성 고객만을 대상으로 정확한 기준치를 설정한다.

3장. (1단계) 방문주기 예측 모델 및 이탈 기준 도출

3.1 왜 기존 이탈 정의 방식이 문제인가

기존 방식은 "특정 기간에 방문했는가/안했는가"라는 이진값으로 이탈을 정의한다. 이 방식의 문제는 다음과 같다.

상황	기존 방식 판단	실제 의미
2024년 매주 오다가 12월부터 뚝 끊김	정상 (2025년에 한 번 왔으니까)	이탈 신호를 놓침
원래 분기에 한 번 오는 고객이 2025년 미방문	이탈	단순히 바쁜 시기였을 수도
2025년에 왔지만 방문 간격이 2배 늘어남	정상 (왔으니까)	빈도 감소 신호를 무시

새로운 정의: 이탈은 사건(event)이 아니라 과정(process)이다.
"안 왔다"가 이탈이 아니라, "점점 덜 오고 있다"가 이탈의 신호다.

3.2 분석 대상 고객 선정

▶ 5회 미만 제외 근거

방문이 4번 이하인 고객은 "이탈했는가"와 "원래 가끔 오는 고객인가"를 구분할 수 없다. 방문 패턴이 존재하려면 최소 5회 이상의 방문 기록이 필요하다.

구분	고객 수	처리 방식
전체 고객	3,589명	전체
5회 미만 제외	1,501명	패턴 없음 → 분석 제외
5회 이상 (분석 대상)	2,088명	패턴 분석 가능한 단골
3등분 가능 고객	1,278명	모델 학습 대상
최종 모델 학습 대상	1,258명	결측값 제거 후

3.3 개인별 3등분 방법론

▶ 왜 개인별 기간인가

달력 기준(2024년 1~4월 등)으로 나누면 각 고객의 가입 시점이 달라서 데이터가 없는 기간이 생긴다. 따라서 각 고객의 첫 방문일~마지막 방문일을 그 고객의 전체 기간으로 정의하고 3등분한다.

예시: 김씨 (2024년 4월 첫 방문 ~ 2025년 12월 마지막 방문, 20개월)

1구간: 2024년 4월 ~ 2024년 10월 (초반)

2구간: 2024년 11월 ~ 2025년 5월 (중반)

3구간: 2025년 6월 ~ 2025년 12월 (후반)

→ 각 구간의 평균 방문 간격을 계산하여 변화 추세를 파악

▶ 왜 3등분인가 (2등분이 아닌 이유)

- 2등분: 전반부 vs 후반부만 비교 → 중간 추세 변화를 놓침
- 3등분: 1→2구간 변화(초반 추세) + 2→3구간 변화(후반 추세) 모두 포착
- 1→2구간 변화율이 피처로 활용되어 조기 감지 가능

▶ 3등분 가능 기준

각 구간에 방문이 최소 2번 이상 있어야 간격 계산이 가능하다. 방문 횟수별 3등분 가능 비율은 아래와 같다.

방문 횟수 기준	전체	3등분 가능	가능 비율
5회 이상	2,088명	1,278명	61.2%
8회 이상	1,652명	1,246명	75.4%
10회 이상	1,420명	1,174명	82.7%

8회 기준 근거: 5회 이상 고객의 중앙값이 15회/24개월 = 한 달 반에 1회.

24개월 3등분 = 구간당 8개월. 8회 이상이면 각 구간에 최소 2~3번이 보장되어 안정적.

팀원 설명 시 이 근거 활용 권장.

3.4 이탈 기준: 변화율 1.5

▶ 변화율 정의

변화율 = 2→3구간 평균 방문 간격 + 1→2구간 평균 방문 간격

변화율	의미
1.0 미만	방문 간격 짧아짐 (충성도 증가)
1.0 ~ 1.2	거의 변화 없음 (안정적 단골)
1.2 ~ 1.5	간격 약간 늘어남 (주의)
1.5 이상	간격 50% 이상 늘어남 → 이탈 위험
2.0 이상	간격 2배 이상 늘어남 → 이탈 임박

▶ 왜 1.5인가 — 데이터 기반 근거

- 전체 고객의 2→3구간 변화율 중앙값: 1.33
- 즉 아무 문제 없는 일반 고객도 후반부에 33% 정도 느려지는 것이 자연스러운 현상
- 1.33은 정상 범위 내 → 1.5 이상을 정상 범위를 벗어난 이탈 위험으로 정의

이 기준은 임의로 정한 것이 아니라 실제 데이터 분포에서 도출한 값이다.
향후 3개 매장 통합 분석 후 재검증 예정.

3.5 Random Forest 모델

▶ 모델 개요

Random Forest는 수백 개의 결정 트리를 만들어 다수결로 예측하는 머신러닝 방법이다. 각 트리는 서로 다른 데이터 샘플과 변수를 보기 때문에 한 트리가 틀려도 나머지가 바로잡는다.

비유: 의사 한 명한테 진단받는 것(결정 트리 1개) vs 의사 500명이 독립적으로 진단하고 다수결로 결정하는 것(Random Forest)

▶ 모델 입력 변수 (피쳐)

변수	의미	비고
방문 횟수	전체 기간 총 방문 횟수	
마지막 방문 경과일	마지막 방문 후 경과 일수	
전체 평균 방문 간격	방문과 방문 사이 평균 일수	
방문 간격 표준편차	방문 불규칙성 측정값	
평균 구매 금액	방문당 평균 구매 금액	
1구간 평균 간격 ★	초반부 방문 간격 평균	3등분 신규 추가
2구간 평균 간격 ★	중반부 방문 간격 평균	3등분 신규 추가
1→2구간 변화율 ★	초반→중반 방문 간격 변화	3등분 신규 추가

★ 표시 3개 변수는 개인별 3등분 설계에서 새로 추가된 변수로, 피쳐 중요도 상위 47.6%를 차지했다. 3등분 설계의 타당성이 데이터로 확인됨.

▶ 이탈 라벨 (정답 데이터)

라벨	조건	고객 수
이탈 위험 (1)	2→3구간 변화율 ≥ 1.5	554명 (44.0%)
정상 (0)	2→3구간 변화율 < 1.5	704명 (56.0%)

▶ 초기 모델 성능 (1개 매장 기준)

지표	값	해석
AUC	0.773	목표치 0.75 초과 달성 ✓
OOB Score	0.715	자체 검증 정확도
F1 점수	0.639	이탈 예측 균형 지표

▶ 이탈 확률 분포 및 활용

구간	고객 수	비율	활용
이탈 임박 (70%+)	354명	28.1%	2단계 실험 대상
이탈 위험 (50~70%)	200명	15.9%	2단계 실험 대상
주의 (30~50%)	178명	14.1%	3단계 실험 대상
정상 (30% 미만)	526명	41.8%	3단계 실험 대상

3.6 모델 고도화 계획 (통합→개별→고도화)

단계	방식	적용 대상
1단계통합 모델	1개 매장 데이터로 학습(현재 완료)	초기 및 신규 매장베이스라인 모델
2단계개별 모델	각 매장 데이터가 충분히 쌓이면매장별 파인튜닝	기존 매장정확도 향상
3단계고도화 통합 모델	5개 매장 데이터 통합 재학습	6번째 이후 신규 매장데이터 없어도 즉시 적용

4장. (2단계) LLM vs 규칙 기반 문자 효과 실험

4.1 연구 질문

LLM이 생성한 개인화 문자가 규칙 기반 템플릿 문자보다 이탈 위험 고객의 재방문을 더 효과적으로 유도하는가?

4.2 실험 대상

항목	내용
대상 고객	실험 시작일 기준 이탈 확률 50% 이상 고객
현재 추정 인원	554명 (실험 시작 시 재산출)
그룹 A (LLM)	277명 — LLM 개인화 문자 수신
그룹 B (규칙)	277명 — 규칙 기반 템플릿 문자 수신
그룹 배정 방식	이탈 확률 내림차순 정렬 후 A/B/A/B 순 층화 배분→ 두 그룹의 이탈 확률 평균/중앙값 동일하게 유지
그룹 고정 시점	실험 시작일 1회 결정 후 실험 기간 동안 고정

그룹 고정 이유: 실험 도중 새로 이탈 위험이 된 고객을 추가하면 A/B 균형이 깨지고, 실험 시작 시점이 다른 고객이 섞여 효과 측정이 복잡해진다.
→ 실험 시작일 기준으로 고정하고, 새로 이탈 위험이 된 고객은 다음 코호트로 관리.

4.3 발송 방식

항목	내용
발송 주기	하루 1회
발송 방식	시스템 자동 발송 (사장님이 고기 종류와 가격 입력 시 자동 생성·발송)
발송 지속	실험 기간 동안 재방문 여부와 무관하게 계속 발송
그룹별 차이	A그룹: LLM 개인화 문자 / B그룹: 규칙 기반 템플릿 문자

항목	내용
발송 횟수	A그룹과 B그룹 동일 (시스템이 컨트롤)

4.4 B그룹 규칙 기반 문자 — 템플릿 3종

규칙 기반 문자는 고객 개인 데이터를 전혀 반영하지 않는다. 사장님이 입력한 상품/가격 정보만 담긴다. 3가지 템플릿을 돌아가며 발송한다.

◆ 템플릿 A — 특가/긴급형

[○○정육점] 안녕하세요! 오늘 한우 꽃등심 100g 18,900원 특가입니다. 파채 서비스 드려요.
한정 수량이니 서두르세요! ☎000-0000-0000

◆ 템플릿 B — 안부/감성형

[○○정육점] 안녕하세요 고객님 :) 오랜만에 인사드려요. 오늘 꽃등심 상태가 정말 좋아서
연락드렸어요. 100g 18,900원, 파채 서비스도 드립니다. 들려주세요!

◆ 템플릿 C — 정보형

[○○정육점] 한우 꽃등심 세일 안내. 100g 18,900원 / 파채 서비스. 단체주문 환영.
☎000-0000-0000

세 가지 템플릿은 요일 또는 무작위 순서로 돌아가며 B그룹 전체에 동일하게 발송된다.

4.5 A그룹 LLM 개인화 문자

A그룹은 Depth 2 수준의 개인화를 적용한다. (Depth 설계는 5장 참고)

입력 정보	내용	출처
사장님 입력	오늘 상품명, 가격, 특이사항	사장님 직접 입력
고객 이름	회원명	POS 데이터

입력 정보	내용	출처
마지막 방문 경과일	마지막 방문 후 며칠이 지났는지	방문 데이터
자주 사는 품목	구매 빈도 상위 품목	구매 데이터

◆ LLM 문자 예시 (Depth 2)

안녕하세요 김씨님! 요즘 바쁘신가요, 한동안 못 뵈었네요 :) 항상 찾아주시던 갈비살이랑 불고기용, 오늘따라 상태가 정말 좋아요. 꽃등심도 100g 18,900원 특가로 나왔는데 한번 둘러봐 주세요. 파채도 서비스로 드려요!

4.6 효과 측정

지표	구분	측정 방법
재방문 간격 변화	주 지표	실험 전(직전 3개월) 평균 간격 vs 실험 후(7~11월) 평균 간격 비교→ A그룹 변화폭 vs B그룹 변화폭
재방문율	보조 지표	실험 기간 내 1회 이상 방문한 고객 비율
구매 금액 변화	보조 지표	실험 전후 평균 구매 금액 변화

기준치 설정: 실험 전 직전 3개월(2026년 4~6월)의 평균 방문 간격을 기준으로 사용.
 이유: 전체 활동 기간 평균은 초기 가입 직후 잦은 방문이 포함되어 현재 상태를 과대평가할 수 있다.
 직전 3개월이 현재 방문 패턴을 가장 정확하게 반영한다.

4.7 실험 기간

단계	기간	내용
실험 진행	2026년 7월 1일 ~ 11월 30일 (5개월)	A/B 그룹 문자 발송 및 방문 추적
결과 정리	2026년 12월	A vs B 효과 분석 및 보고

5개월 기간 근거: 전형적인 고객(한 달 반에 1회 방문)이 5개월 동안 약 3번 이상의 방문 기회를 가진다. 패턴 변화를 관찰하기에 충분한 기간이다.

5장. (3단계) LLM 개인화 Depth 실험

5.1 연구 질문

LLM 개인화가 깊을수록(더 많은 고객 정보를 반영할수록) 재방문 빈도가 증가하는가?

5.2 Depth 설계

Depth는 LLM에 입력되는 고객 개인 정보의 깊이를 의미한다. Depth가 높을수록 더 많은 개인 정보가 반영되며 문자 길이와 개인화 수준이 높아진다.

Depth	사용하는 고객 정보	문자 특성
Depth 1(약한 개인화)	사장님 입력 + 고객 이름 + 마지막 방문 경과일	약 80자이름과 경과일만 반영모든 고객이 비슷한 톤
Depth 2(중간 개인화)★(2)단계 적용	사장님 입력 + 고객 이름 + 마지막 방문 경과일+ 자주 사는 품목	약 120자구매 품목 언급고객 취향이 반영됨
Depth 3(깊은 개인화)	사장님 입력 + 고객 이름 + 마지막 방문 경과일+ 자주 사는 품목 + 평균 방문 주기+ 평균 구매 금액 + 단골 여부	약 180자방문 주기 대비 오래 안 온 것 언급단골 감사 표현 포함고객마다 완전히 다른 문자

Depth 3의 핵심: 이탈 확률이 같은 두 고객도 받는 문자가 완전히 다르다.

고객 A (매주 오던 단골, 갈비살 구매, 32일째 미방문)

→ "김씨님, 매주 보던 얼굴이 한 달이 넘도록 안 보이니 걱정됐어요. 갈비살 오늘 상태 정말 좋아요..."

고객 B (한 달에 한 번, 이유식용 구매, 55일째 미방문)

→ "박씨님, 아이 잘 크고 있나요 :) 이유식용으로 항상 신경 써드리던 부위 오늘 좋은 거 들어왔어요..."

연구 가설: Depth 2가 Depth 3보다 효과적일 수 있다.

Depth 3은 방문 주기까지 직접 언급하여 고객이 "감시받는 느낌"을 받을 수 있다.

Depth 2는 자연스러운 개인화 효과를 유지하면서 부담을 주지 않는 균형점이다.

→ 실험 결과로 검증 예정

5.3 실험 대상

항목	내용
대상 고객	실험 시작일 기준 이탈 확률 50% 미만 고객
현재 추정 인원	704명 (실험 시작 시 재산출)
그룹 D1 (Depth 1)	약 235명
그룹 D2 (Depth 2)	약 235명
그룹 D3 (Depth 3)	약 234명
그룹 배정 방식	이탈 확률 기준 층화 배분→ 세 그룹의 이탈 확률 분포 동일하게 유지
이탈 확률 구간 분포	30~50% (주의) / 30% 미만 (정상) 고객에게 그룹에 균등하게 배분

5.4 효과 측정

지표	구분	측정 방법
재방문 간격 변화	주 지표	실험 전(직전 3개월) vs 실험 후Depth 1 → 2 → 3으로 갈수록 간격이 더 줄어드는가?
Depth별 효과 크기	핵심 분석	D1 vs D2 vs D3 효과 크기 비교어느 depth가 가장 효과적인가?
재방문 빈도	보조 지표	실험 기간 내 방문 횟수 변화
구매 금액 변화	보조 지표	실험 전후 평균 구매 금액

5.5 실험 기간

2단계와 동일하게 2026년 7월 1일 ~ 11월 30일 (5개월) 진행한다. 대상 고객이 겹치지 않아 동시 진행이 가능하며, 계절 효과도 동일하게 통제된다.

5.6 (2)단계와 (3)단계 동시 진행 구조

구분	2단계	3단계
대상	이탈 확률 50% 이상	이탈 확률 50% 미만
그룹	A (LLM Depth 2) vs B (규칙)	D1 vs D2 vs D3
인원	각 277명 (총 554명)	각 235명 (총 704명)
발송 내용	개인화 문자 vs 템플릿 문자	Depth별 개인화 수준 차이
기간	7~11월 (5개월)	7~11월 (5개월)
겹침 여부	없음 (50% 기준으로 완전 분리)	없음

6장. 실험 운영 시스템

6.1 자동 발송 시스템 구조

CTO 확인 완료. 아래 구조로 자동 발송 시스템을 구현한다.

단계	내용
1. 사장님 입력	앱에서 오늘 상품 종류, 가격, 특이사항 선택/입력
2. 그룹 라벨 확인	시스템이 각 고객의 그룹 라벨 확인(A그룹 / B그룹 / D1 / D2 / D3)
3. 문자 생성	A그룹/D그룹: 해당 Depth 프롬프트로 LLM 문자 생성 B그룹: 오늘 해당하는 템플릿 선택
4. 자동 발송	각 그룹별로 다른 문자 자동 발송(사장님은 개입 없음)

6.2 핵심 운영 원칙

- 사장님 개입 최소화: 상품 입력 버튼 하나로 전체 발송 자동화
- 그룹 블라인드: 사장님은 어떤 고객이 어느 그룹인지 알 수 없음 (실험 무결성 보호)
- 발송 이력 기록: 모든 발송 내역, 재방문 여부, 구매 금액 자동 기록
- 실험 종료 후 공개: 11월 30일 이후 그룹 배정 공개 및 결과 분석

7장. 성과 목표 및 기대 효과

7.1 정량적 성과 목표

단계	지표	목표치	측정 방법
1단계	AUC	0.75 이상	Random Forest 모델 검증
1단계	F1 점수 (최종)	0.70 이상 (3개 매장 통합 후)	모델 성능 지표
2단계	LLM vs 규칙 재방문 간격 차이	통계적 유의미한 차이 확인	t-test 또는 Mann-Whitney
3단계	Depth별 재방문 간격 차이	Depth 간 유의미한 차이 확인	ANOVA 또는 Kruskal-Wallis
특허	특허 출원	2건	특허1: 이탈 기준 도출 방법 특허2: LLM depth 발송 시스템

7.2 연구의 독창성

- 소규모 오프라인 매장(정육점) 특허 이탈 기준 도출 방법론 — 기존 연구 전무
- 개인별 방문 패턴 변화율 기반 이탈 정의 — 단순 미방문 이진값 방식 극복
- LLM 개인화 depth별 마케팅 효과 실증 — 동일 이탈 확률 고객도 완전히 다른 문자
- 디지털 취약계층(50~60대 사장님)이 버튼 하나로 쓸 수 있는 완전 자동화 구조

7.3 특허 가능성

특허 1 — 소규모 오프라인 매장의 개인별 방문 패턴 기반 이탈 기준 도출 방법

핵심 클레임:

- 고객의 전체 활동 기간을 3등분하여 구간별 방문 간격 변화율을 계산하는 방법
- 전체 고객 변화율 중앙값(1.33)을 기준으로 업종 특허 이탈 임계값을 데이터로 도출하는 방법
- 방문 횟수에 따라 분석 대상을 동적으로 선별하는 방법 (5회 미만 제외 등)

차별점:

- 기존 CRM은 동일 세그먼트에 동일 문자.
- 이탈 확률이 같아도 고객마다 완전히 다른 문자를 LLM이 자동 생성하는 구조는 없음.

특허 2 — LLM 개인화 depth 기반 마케팅 메시지 생성 및 자동 발송 시스템

핵심 클레임:

- 고객 이탈 확률 구간에 따라 LLM 프롬프트에 입력되는 개인화 정보의 깊이(depth)를 자동으로 결정하는 방법
- 동일한 이탈 확률을 가진 고객에게도 개인 데이터에 따라 완전히 다른 메시지를 생성하는 방법
- 점주 입력(상품/가격)과 고객 개인 데이터를 조합하여 LLM이 자동으로 문자를 생성·발송하는 시스템

차별점:

- 기존 이탈 예측 특허는 단일 서비스 단일 모델.
- 멀티 매장 환경에서 통합↔개별 모델을 동적으로 전환하는 구조는 없음.

특허 3 — 멀티 매장 환경에서 통합-개별 모델 전환 시스템

핵심 클레임:

- 신규 매장은 통합 모델로 시작하고, 데이터 축적 후 개별 모델로 자동 전환하는 방법
- 개별 매장 모델이 다시 통합 모델 고도화에 기여하는 순환 학습 구조
- 매장 데이터 부족 시 통합 모델을 베이스라인으로 활용하는 방법

차별점:

- 오프라인 매장에서 방문 간격 변화를 효과 지표로 쓰는 방법이 독창적.
- 기존은 온라인 클릭률/구매전환율 중심.

4단계, 5단계 (2027년 연구)

RF 모델 고도화

- 1개 매장 → 5개 매장 통합 모델 → 신규사업장 적용 → 개별 사업장 고도화
- 계절성 처리 적용 후 성능 변화 측정
- AUC 0.75 → 0.80 이상 목표
- 3등분 불가 810명 처리 방법 개발

효과 지속성 및 최적 발송 주기 연구

- 언제, 얼마나 자주 보내는 게 최적인가
- 하루 1회 vs 주 3회 vs 주 1회
- 발송 시간대 (오전 vs 저녁)
- 효과가 시간이 지남에 따라 감소하는지 (habituation effect)

개인화 특성 확장

- 날씨 연동 (추운 날 → 국거리용 고기 추천)
- 기념일 감지 (마지막 방문 기준 1주년 등)
- 가족 구성 추정 (이유식용 구매 → 영아 자녀 있음)
- 구매 품목 다양성 (항상 같은 걸 사는 고객 vs 다양하게 사는 고객)

이탈 후 재유입 패턴 연구

이탈한 고객이 다시 돌아오는 패턴

- 이탈 후 얼마 만에 재방문하는가
- 재방문을 유도하는 요인이 뭔가 (명절? 할인? 우연?)
- 재유입 고객에게 최적 개입 시점은 언제인가

자연 재방문하는 패턴을 보면 "문자 효과의 한계"도 같이 측정

이탈 예측 → 구매 금액 예측으로 확장

"올 때 얼마나 살 것인가"까지 예측하는 모델로 확장

- 고객별 예상 구매 금액 예측
- 고가 구매 고객의 이탈이 더 중요하니까 가중치를 다르게 줄 수 있음
- "이탈 위험 × 예상 구매 금액 = 이탈 손실 예상액"으로 우선순위 결정

사장님 행동 패턴과 고객 반응 상관관계

발송 빈도, 발송 시간, 상품 종류 선택 등 사장님의 앱 사용 패턴이 고객 반응에 어떤 영향을 미치는지 분석.

- 열심히 입력하는 사장님 vs 가끔 입력하는 사장님의 재방문을 차이
- 어떤 상품을 넣을 때 반응이 좋은가
- 이게 쌓이면 사장님한테 "오늘은 삼겹살보다 갈비살을 추천하세요" 같은 상품 추천도 가능

추후 TIPS 과제 방향

자동화 고도화 (Zero-task) - 사장님 입력조차 없애는 단계.

지금: 사장님이 상품/가격 입력 → 자동 발송

추후: 사장님 입력 없이 AI가 알아서 판단하고 발송

- AI가 매장 매출 데이터를 보고 "오늘 삼겹살 재고가 많다"를 스스로 감지
- 이탈 위험 고객 중 삼겹살을 자주 산 고객에게 자동 발송
- 사장님은 아무것도 안 해도 됨

부록. 미발송 그룹(C그룹) 포함 여부 검토

2단계 실험에서 미발송 그룹(C그룹)을 포함할지 여부에 대한 검토 내용이다.

구분	내용
C그룹 포함 시 이점	문자 마케팅 자체의 효과를 독립적으로 검증 가능("LLM이 좋은 것인가" + "문자 자체가 좋은 것인가" 동시 답변)
C그룹 포함 시 단점	사장님께 "특정 고객에게 문자를 보내지 않겠다"는 양해 필요 그룹당 인원 감소 (277명 → 185명으로 축소) 통계적 검정력 약화
현재 결정	C그룹 제외 (A vs B만 비교) 이유: 문자 마케팅 자체의 재방문 효과는 기존 선행연구에서 입증되어 있음
재검토 조건	선행연구 확인 결과 정육점 등 소규모 오프라인 매장에서 문자 마케팅 효과를 직접 실증한 연구가 없다면 C그룹 포함 재검토